



Examen final: Interpretabilidad y Causalidad en Machine Learning

¡Les felicitamos por haber terminado el curso de Interpretabilidad y Causalidad en Machine Learning !

A continuación describiremos las instrucciones del examen final. La fecha de entrega es el **Miércoles 19 de agosto**.

Este examen evalúa la comprensión de métodos de inferencia causal (IPW, Matching, Modelado de Resultados) usando el dataset clásico de [LaLonde](https://github.com/VioletteGL/Interpretabilidad-y-Causalidad-Bourbaki/blob/main/lalonde_data.csv).

https://github.com/VioletteGL/Interpretabilidad-y-Causalidad-Bourbaki/blob/main/lalonde_data.csv

1. Identificar la variable de tratamiento. Graficar distribuciones del puntaje de propensión y comentar sobre solapamiento/positividad.

Ajustar modelo de puntaje de propensión y construir pesos IPW para ATE.

Ajusta un modelo del resultado Y con covariables (X) y tratamiento (D) (p. ej., regresión lineal regularizada o árboles); calcula ATE y ATT. Comparar los resultados con y sin IPW.

Construir un grafo causal bayesiano que represente las relaciones plausibles entre tratamiento, resultado y las covariables identificadas. Utiliza diagramas de causa-efecto (DAGs) explícitos. Determinar si existe un conjunto de variables que satisfaga el criterio de backdoor para estimar el efecto causal del tratamiento sobre el resultado.



Examen final: Interpretabilidad y Causalidad en Machine Learning

2. Contestar la siguiente pregunta por medio de un detallado razonamiento matemático o mediante algunos experimentos documentados en un cuaderno de Python:

¿El teorema de Frisch–Waugh–Lovell prohíbe el fenómeno paradójico de Simpson?

Consideremos un problema con variables como las que hemos utilizado hasta en el curso: la variable del tratamiento X , la variable objetivo Y y covariables Z . Consideremos también un modelo lineal $f(X, Z) = \hat{Y}$ con coeficientes como a continuación.

$$\hat{Y} = \beta_X \cdot X + \beta_Z \cdot Z. \quad (02.2)$$

Recordemos que las técnicas comunes de interpretabilidad pueden confundirnos en un estudio causal. El Teorema de Firsh-Waugh-Lovell proporciona una manera alternativa para obtener el coeficiente β_X .

Consideremos las siguientes regresiones parciales, junto con sus respectivos errores:

(I) $\hat{Y}_Z = \beta_Z^Y \cdot Z$, con error $\epsilon_Y = \hat{Y}_Z - Y$.

(II) $\hat{X}_Z = \beta_Z^X \cdot Z$, con error $\epsilon_X = \hat{X}_Z - X$.

Calculemos una regresión con ellas.

$$\hat{\epsilon}_Y = \beta_X' \cdot \epsilon_X \quad (02.3)$$

Notemos que solamente hemos realizado regresiones univariadas para calcular todos los ϵ hasta ahora. Esto por supuesto, es muy valioso computacionalmente incluso si la cantidad de covariables es grande.

El **teorema de Fircsh - Waugh - Lovell** asegura que el coeficiente de la regresión 02.2, es exactamente el mismo coeficiente de la regresión de los errores 02.3:

$$\beta_X' = \beta_X \quad (02.4)$$

3. Calcula el ATE mediante Double Machine Learning y compara tu resultado con tu respuesta de la pregunta 2.

Quienes deseen continuar con su aprendizaje al terminar el curso les recomendamos inscribirse a alguna de las continuaciones.

Por favor acercarse a los profesores para preguntarles cuál de ellos es ideal para su perfil

1. Aplicaciones Financieras de ML & AI [Temario.](#)
2. Machine Learning & AI. [Temario.](#)
3. Track de Ciencia de Datos. [Temario.](#)
4. Matemáticas para Ciencia de Datos.

 info@colegio-bourbaki.com

 +52 56 2141 7850

Colegio de Matemáticas Bourbaki

