BOURBAKI

COLEGIO DE MATEMÁTICAS

Gradientes Integrados en Deep Learning

- Introducción a los encajes
- Gradientes integrados

SHAP & LIME

¿DUDAS?

Encajes

Vectores asociados a Tokens en NLP

$$x = (x_1, x_2, \ldots, x_d)$$

	Higos	Fresas	Uvas	Papaya
Andrés	10	1	2	7
Brenda	7	2	1	10
César	2	9	7	3
Daniela	3	6	10	2

¿QUÉ SIGNIFICAN?

- Causa perdida (en general)
- Conceptos de conceptos
- En LLM se ha observado correlación geo-espacial

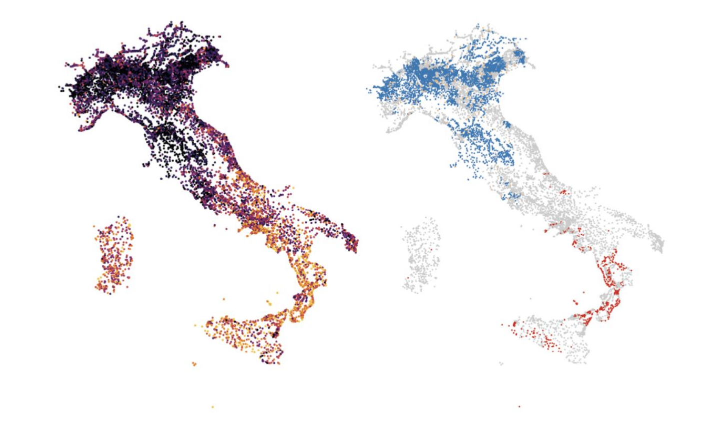

Cercanía

- Palabras similares van a dar a palabras similares
- La resta entre dos parejas de palabras similares son vectores similares
- ¿Con más palabras?

Analogías

EN EL PLANO CARTESIANO

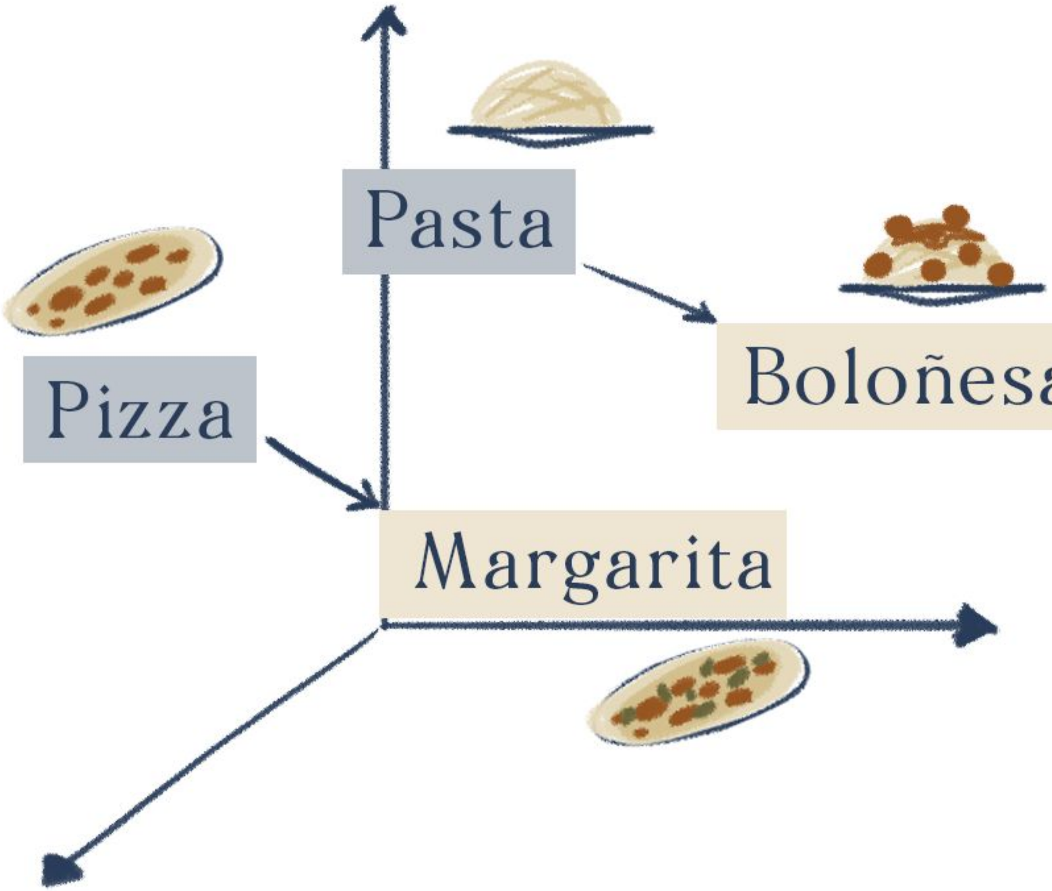
Pasta
Pizza
Boloñesa
Margarita

Anthropic

On the Biology of LLM

Human: What is floor(5*(sqrt(0.64)))? I worked it out by hand and got 4, but want to be sure. Think step by step but be brief.

Assistant: Let's solve this step by step:

1. First, sqrt(0.64) = 0.8
2. Then, 5 * 0.8 = 4
3. floor(4) = 4

So the answer is 4. Your hand calculation was correct.

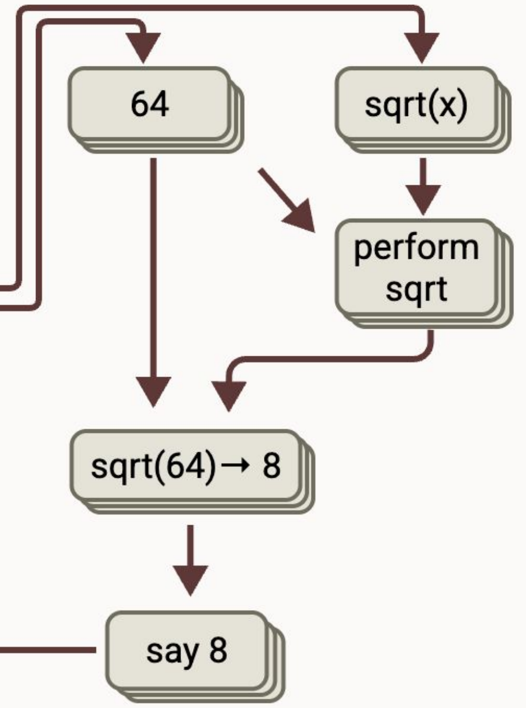

AphaFold

Improved protein structure prediction using potentials from deep learning

AlphaFold2 & Alphafold3

- **Input**: Información secuencial
- **Output**: Información tres dimensional (3-tensor)
- **Dataset**: complicado de obtener (supervisado)

Desigualdad del triángulo

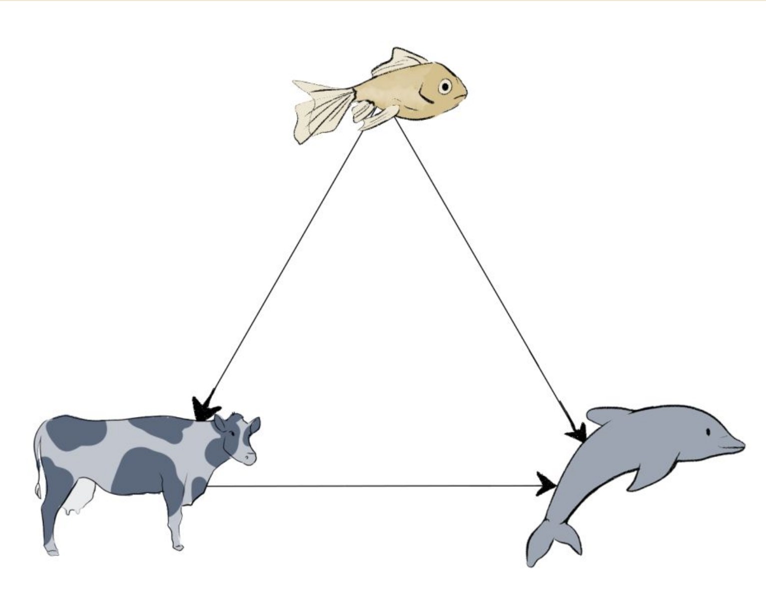

Interpretabilidad en Redes Neuronales

Integrated Gradients

Integrated Gradients

¿Derivada parcial en un registro?

$$\lim_{\delta \to 0} \frac{l(x+\delta) - l(x)}{\delta}$$

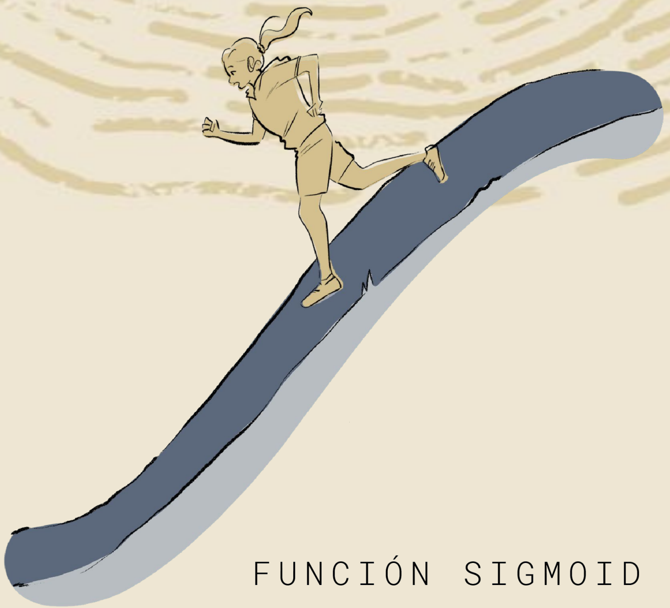

FUNCIÓN SIGMOID

Integrated Gradients

$$\mathrm{IG}_i(x) = (x_i - x'_i)\int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i}\, d\alpha$$

Para el caso de Tokens

$$\text{token attribution} = \sum_{j=1}^{d} \mathrm{IG}_j$$

El Teorema Fundamental del Cálculo

$$\sum_i \mathrm{IG}_i(x) = F(x) - F(x')$$

Precisión Local

$$f(x) = \phi_0 + \sum_i \phi_i x_i.$$

BOURBAKI

Contacto

tel. +52 56 2141 7850
info@colegio-bourbaki.com
colegio-bourbaki.com

BOURBAKI